


ANALIZA I DETEKCIJA

PREVARA U

MOBILNOM

BANKARSTVU



Mila Budimiriović

IN22/2021

OPIŠ SKUPA PODATAKA

Naziv: Mobile Money Fraud Detection Dataset

Kontekst: Sintetički skup podataka mobilnih novčanih transakcija kreiran za istraživanje detekcije prevara, zasnovan na realnim finansijskim logovima

Datoteke: transactions.csv, balance_features.csv, fraud_scenario_labels.csv, network_features.csv, risk_features.csv, sender_behavior_features.csv, sender_receiver_features.csv, temporal_features.csv (ukupno 8)

Ukupna veličina: 2.7GB

Broj zapisa: 6.362.620 transakcija

SEMANTIKA KOLONA



transactions.csv

- transaction_id - jedinstveni identifikator transakcije
- type - tip transakcije (CASH-IN, CASH-OUT, DEBIT, PAYMENT, TRANSFER)
- amount - iznos transakcije u lokalnoj valuti
- nameOrig - korisnik koji je inicirao transakciju
- oldbalanceOrg - stanje na računu pošiljaoca pre transakcije
- newbalanceOrig - novo stanje na računu pošiljaoca nakon transakcije
- nameDest - primalac transakcije (korisnički račun/merchant)
- oldbalanceDest - početno stanje na računu primaoca pre transakcije
- newbalanceDest - novo stanje na računu primaoca nakon transakcije
- isFraud - oznaka da li je transakcija lažna (1 za prevaru, 0 za regularnu transakciju)
- isFlaggedFraud - oznaka sistema za sumnjive transakcije
- is_merchant_dest – oznaka da li je odredišni račun trgovac (merchant)
- is_customer_dest – oznaka da li je odredišni račun običan korisnik (customer)



temporal_features.csv



- transaction_id - jedinstveni identifikator transakcije
- day – broj dana u mesecu
- hour – sat u danu kada se transakcija izvršila
- period_of_day – doba dana kada je transakcija izvršena (npr. popodne, večer, itd.)
- is_night – oznaka da li se transakcija dogodila tokom noći (1 za noć, 0 za ostala doba dana)
- is_first_week – oznaka da li se transakcija dogodila tokom prve nedelje u mesecu
- is_first_half_month – oznaka da li se transakcija dogodila u prvoj polovini meseca



sender_receiver_features.csv



- transaction_id - jedinstveni identifikator transakcije
- nameOrig – korisnički račun koji je inicirao transakciju (pošiljalac)
- nameDest – račun korisnika ili trgovca koji je primio transakciju (primalac)
- same_receiver_count_24h – broj transakcija između istog pošiljaoca i primaoca tokom poslednja 24 sata
- sender_receiver_tx_count_so_far – broj prethodnih transakcija između istog pošiljaoca i primaoca pre trenutne transakcije
- is_new_receiver_for_sender – oznaka da li je ovo prva zabeležena transakcija između ovog pošiljaoca i ovog primaoca (1 za da, 0 za ne)

sender_behavior_features.csv



- transaction_id - jedinstveni identifikator transakcije
- nameOrig – korisnički račun koji je inicirao transakciju (pošiljalac)
- sender_tx_count_total_so_far – ukupan broj prethodnih transakcija koje je pošiljalac izvršio pre trenutne transakcije
- sender_tx_count_1h – broj transakcija koje je pošiljalac izvršio tokom istog sata
- sender_tx_count_24h – broj transakcija koje je pošiljalac izvršio u poslednja 24 sata
- sender_total_amount_24h – ukupan iznos novca koji je pošiljalac poslao u poslednja 24 sata
- sender_avg_amount_24h – prosečan iznos transakcije pošiljaoca u poslednja 24 sata
- amount_to_sender_avg_ratio – odnos između iznosa trenutne transakcije i pošiljaočevog proseka u poslednja 24 sata
- sender_unique_receivers_24h – broj različitih primalaca kojima je pošiljalac slao novac u poslednja 24 sata

risk_features.csv



- transaction_id – jedinstveni identifikator transakcije
- risk_score_rule_based – bodovi rizika zasnovani na poslovnim pravilima
- risk_level – kategorija rizika izvedena iz bodova rizika (npr. nizak, srednji, visok)
- risk_reason_count – broj detektovanih signala rizika za datu transakciju
- high_amount_flag – oznaka da li je iznos transakcije neuobičajeno visok (1 za da, 0 za ne)
- high_velocity_flag – oznaka da li pošiljalac ima neuobičajeno visoku učestalost (brzinu) transakcija u kratkom vremenskom periodu
- new_receiver_flag – oznaka da li je ovo prva uočena transakcija između tog pošiljaoca i primaoca
- many_to_one_receiver_flag – oznaka da li je primalac primio sredstva od velikog broja različitih pošiljalaca
- suspicious_cashout_flag – oznaka za sumnjiv obrazac podizanja/isplate novca (cash-out) na osnovu iznosa, brzine ili ponašanja primaoca
- large_transfer_flag – oznaka za veliki transfer novca koji prelazi prag definisan poslovnim pravilom

network_features.csv



- transaction_id – jedinstveni identifikator transakcije
- nameOrig – korisnički račun koji je inicirao transakciju (pošiljalac)
- nameDest – račun korisnika ili trgovca koji je primio transakciju (primalac)
- sender_out_degree_so_far – broj jedinstvenih primalaca sa kojima se pošiljalac prethodno povezao
- receiver_in_degree_so_far – broj jedinstvenih pošiljalaca koji su prethodno slali novac ovom primaocu
- receiver_tx_count_so_far – ukupan broj prethodnih transakcija koje je ovaj primalac primio do sada
- receiver_received_amount_so_far – ukupan iznos novca koji je ovaj primalac prethodno primio
- sender_receiver_network_count_so_far – broj prethodnih transakcija u mreži koje su se desile isključivo između ovog konkretnog para pošiljaoca i primaoca

fraud_scenario_labels.csv



- transaction_id – jedinstveni identifikator transakcije
- fraud_scenario – konkretan scenario dodeljen transakciji na osnovu ponašanja (npr. normal (regularno), original fraud (izvorna prevara), large transfer (veliki transfer), suspicious cash-out (sumnjiva isplata) itd.)
- scenario_group – šira kategorija kojoj scenario pripada (npr. normal ili engineered_suspicious_pattern)
- is_original_fraud_label – oznaka da li je transakcija prevara prema izvornoj isFraud labeli iz PaySim dataset-a (1 za da, 0 za ne)
- is_engineered_scenario – oznaka da li je scenario kreiran na osnovu inženjerskih/poslovnih pravila, umesto da je preuzet direktno iz izvorne PaySim labele (1 za da, 0 za ne)

balance_features.csv



- transaction_id – jedinstveni identifikator transakcije
- balance_diff_orig – razlika između stanja na računu pošiljaoca pre i nakon transakcije
- balance_diff_dest – razlika između stanja na računu primaoca nakon i pre transakcije
- expected_newbalanceOrig – očekivano novo stanje na računu pošiljaoca nakon transakcije (izračunato na osnovu iznosa transakcije)
- expected_newbalanceDest – očekivano novo stanje na računu primaoca nakon transakcije (izračunato na osnovu iznosa transakcije)
- orig_balance_error – razlika između stvarnog (uočenog) i očekivanog stanja na računu pošiljaoca nakon transakcije
- dest_balance_error – razlika između stvarnog (uočenog) i očekivanog stanja na računu primaoca nakon transakcije
- is_sender_balance_zero_after – oznaka da li je stanje na računu pošiljaoca palo na nulu nakon transakcije (1 za da, 0 za ne)

balance_features.csv



- `is_dest_balance_zero_before` – oznaka da li je stanje na računu primaoca bilo nula pre transakcije (1 za da, 0 za ne)
- `is_dest_balance_missing` – oznaka da li podaci o stanju na računu primaoca nedostaju (čest slučaj kada je primalac trgovac/merchant)
- `leakage_warning` – upozoravajuća oznaka koja ukazuje na to da varijable povezane sa stanjem računa mogu uneti curenje podataka (data leakage) u modele za detekciju prevara




PROLAZ KROZ DATOTEKE PUTEM KLJUČEVA

- transactions.csv → transaction_id, nameOrig, nameDest
- balance_features.csv → transaction_id
- temporal_features.csv → transaction_id
- sender_behavior_features.csv → transaction_id, nameOrig
- sender_receiver_features.csv → transaction_id, nameOrig, nameDest
- network_features.csv → transaction_id, nameOrig, nameDest
- risk_features.csv → transaction_id
- fraud_scenario_labels.csv → transaction_id



PRIMER PROSTIRANJA PODATAKA

- transactions.csv → transaction_id = TXN_00001, nameOrig = C123456789, nameDest = C987654321, type = TRANSFER, amount = 250000
- balance_features.csv → transaction_id = TXN_00001, balance_diff_orig = -250000, is_sender_balance_zero_after = 1
- temporal_features.csv → transaction_id = TXN_00001, hour = 2, is_night = 1, is_first_week = 0
- sender_behavior_features.csv → transaction_id = TXN_00001, sender_tx_count_1h = 5, amount_to_sender_avg_ratio = 8.3
- risk_features.csv → transaction_id = TXN_00001, risk_level = high, suspicious_cashout_flag = 1
- fraud_scenario_labels.csv → transaction_id = TXN_00001, fraud_scenario = suspicious cash-out, is_original_fraud_label = 1



PREDLOG LOGIČKE ŠEME

KOLEKCIJA TRANSACTIONS

```
{
  "_id": "TXN_00001",

  "type": "TRANSFER",
  "amount": 250000,

  "sender": {
    "nameOrig": "C123456789",
    "oldbalanceOrg": 250000,
    "newbalanceOrig": 0,
    "behavior": {
      "sender_tx_count_total_so_far": 45,
      "sender_tx_count_1h": 5,
      "sender_tx_count_24h": 12,
      "sender_total_amount_24h": 980000,
      "sender_avg_amount_24h": 81666,
      "amount_to_sender_avg_ratio": 3.06,
      "sender_unique_receivers_24h": 7
    },
    "network": {
      "sender_out_degree_so_far": 14
    }
  },
}
```

```
  "receiver": {
    "nameDest": "C987654321",
    "oldbalanceDest": 0,
    "newbalanceDest": 0,
    "is_merchant_dest": 0,
    "is_customer_dest": 1,
    "network": {
      "receiver_in_degree_so_far": 23,
      "receiver_tx_count_so_far": 45,
      "receiver_received_amount_so_far":
5600000
    },
    "sender_receiver_relation": {
      "same_receiver_count_24h": 3,
      "sender_receiver_tx_count_so_far": 0,
      "is_new_receiver_for_sender": 1,
      "sender_receiver_network_count_so_far": 0
    },
  },
```

```
  "temporal": {
    "day": 14,
    "hour": 2,
    "period_of_day": "evening",
    "is_night": 1,
    "is_first_week": 0,
    "is_first_half_month": 1
  },

  "balance_analysis": {
    "balance_diff_orig": -250000,
    "balance_diff_dest": 0,
    "expected_newbalanceOrig": 0,
    "expected_newbalanceDest":
250000,
    "orig_balance_error": 0,
    "dest_balance_error": -250000,
    "is_sender_balance_zero_after": 1,
    "is_dest_balance_zero_before": 1,
    "is_dest_balance_missing": 0,
    "leakage_warning": 1
  }
}
```

PREDLOG LOGIČKE ŠEME

KOLEKCIJA RISKS

```
{ "_id": "TXN_00001",  
  "transaction_id": "TXN_00001",
```

```
  "risk": {  
    "risk_score_rule_based": 87,  
    "risk_level": "high",  
    "risk_reason_count": 4,  
    "flags": {  
      "high_amount_flag": 1,  
      "high_velocity_flag": 1,  
      "new_receiver_flag": 1,  
      "many_to_one_receiver_flag": 1,  
      "suspicious_cashout_flag": 0,  
      "large_transfer_flag": 1  
    }  
  },  
  
  "fraud_label": {  
    "isFraud": 1,  
    "isFlaggedFraud": 0,  
    "fraud_scenario": "large transfer",  
    "scenario_group": "engineered_suspicious_pattern",  
    "is_original_fraud_label": 0,  
    "is_engineered_scenario": 1  
  }  
}
```

PREDLOZI AGREGACIJE

iz perspektive Fraud Analyst-a

1. Koji tipovi transakcija ka novim primaocima (`is_new_receiver_for_sender = 1`) najčešće rezultuju prevarama, i kako se prosečan `risk_score` razlikuje u zavisnosti od toga da li je primalac merchant ili customer?
2. U kom periodu dana je `suspicious_cashout_flag` najčešći, koji `fraud_scenario` dominira u tom periodu i koliki je prosečan iznos tih transakcija u odnosu na ostale?
3. Koji primaoci su primili novac od najvećeg broja različitih pošiljalaca, koliki je procenat tih transakcija označen kao prevara i koji `risk_level` dominira među njima?
4. Koje kombinacije rizičnih oznaka se najčešće pojavljuju kod kvarnih transakcija i u kom periodu dana se te transakcije najčešće dešavaju?
5. Koliki procenat transakcija gde je stanje pošiljaoca palo na nulu nakon transakcije je označen kao prevara, grupisano po tipu transakcije i nivou rizika, i kako se prosečan `risk_score` razlikuje između originalnih PaySim prevara i engineered scenarija?

IN
22/2021

